Les traders artificiels sont-ils surconfiants ?

Analyse de la calibration des niveaux de confiance dans un système de trading multi-modèles LLM

Nicolas Bourgeois

Mars 2026

Résumé

Les grands modèles de langage (LLM), tels que GPT-4, ont démontré une capacité remarquable à évaluer les implications économiques des titres d'actualité et à prédire les mouvements boursiers sans entraînement financier spécifique. Cependant, le déploiement de systèmes décisionnels fondés sur plusieurs LLM concurrents soulève une question fondamentale, héritée de la finance comportementale : ces agents artificiels sont-ils sujets aux mêmes biais cognitifs que les humains, en particulier la surconfiance ? Cette étude s'articule autour de quatre axes : la déconstruction de la surconfiance chez les traders humains, l'intégration des LLM dans la prise de décision financière, la calibration des niveaux de confiance au sein de ces modèles, et l'éclairage apporté par les travaux récents suggérant que les "erreurs" systématiques des LLM pourraient refléter une forme de rationalité adaptative plutôt qu'une irrationalité pure. L'expérimentation repose sur un système mettant en concurrence quatre modèles sur un univers de 450 instruments financiers durant 72 heures. L'analyse mobilise la métrique d'*Expected Calibration Error* (ECE) pour quantifier la miscalibration de chaque modèle. Les données utilisées dans cette étude sont disponibles en open data. [1]

Table des matières

1 La surconfiance humaine en finance : définitions et impact sur le trading 3

2 Les LLM en tant qu'agents d'information financière 3

3 Calibration et expression de l'incertitude dans les LLM 4

4 Les "erreurs" systématiques des LLM : irrationalité ou rationalité adaptative ? 4

5 Description de l'expérimentation 5

5.1 Infrastructure technique et outils 5

5.2 Protocole expérimental 6

5.3 Mesure de la surconfiance 7

1. Dataset complet : Lien Github. Le code source du système de trading n'est pas rendu public en raison des risques associés à la diffusion d'un outil de trading autonome opérationnel.

6 Analyse des résultats **7**
6.1 Hétérogénéité des agents 8

7 Discussion **9**
7.1 Réplicabilité de l'expérience et robustesse statistique 9
7.2 Corriger les biais : une question normative 9
7.3 La place du trader humain face à un système potentiellement moins biaisé 10

8 Conclusion **11**

9 Annexe **14**

1 La surconfiance humaine en finance : définitions et impact sur le trading

Pour analyser la surconfiance des agents artificiels, il est crucial de s'appuyer sur la taxonomie de la surconfiance humaine. La littérature psychologique et économique a historiquement confondu plusieurs concepts sous le terme unique de "surconfiance". Moore et Healy 2008 clarifient ce biais en le divisant en trois catégories distinctes :

- **La surestimation (*overestimation*)** de ses propres performances réelles.
- **Le sur-positionnement (*overplacement*)** ou effet "mieux que la moyenne", où un individu se juge plus compétent que ses pairs.
- **La sur-précision (*overprecision*)**, qui correspond à une certitude excessive quant à l'exactitude de ses croyances, souvent mesurée par des intervalles de confiance trop étroits.

En finance, les modèles théoriques classiques postulent que la surconfiance, modélisée sous forme de sur-précision (les investisseurs sous-estiment la variance des signaux financiers), conduit à un volume de trading excessif. Toutefois, les validations empiriques nuancent ce postulat. Glaser et Weber 2007 démontrent que ce n'est pas la sur-précision (la mauvaise calibration) qui pousse les investisseurs individuels à trader davantage, mais plutôt le sur-positionnement. Les individus qui se considèrent au-dessus de la moyenne en matière de compétences d'investissement affichent des volumes de transactions significativement plus élevés. Transposer ce cadre aux agents LLM nécessite donc d'évaluer non seulement leur capacité à générer des probabilités bien calibrées, mais aussi leur propension à manifester des comportements analogues à la surestimation de leurs propres prédictions boursières.

2 Les LLM en tant qu'agents d'information financière

L'utilisation de modèles de langage pour le traitement de l'information financière s'est avérée particulièrement prometteuse. Lopez-Lira et Tang 2025 montrent que GPT-4 est capable de prédire la réaction immédiate du marché (à la hausse ou à la baisse) face à des actualités financières avec un taux de réussite d'environ 90 % pour les portefeuilles, surpassant largement les méthodes d'analyse de sentiment traditionnelles ou les modèles pré-génératifs comme BERT ou GPT-2. Ces résultats suggèrent que les LLM perfectionnés agissent comme des processeurs d'information capables de résoudre des asymétries de marché causées par une diffusion lente de l'information.

Cependant, la manière dont on interroge ces modèles influence fortement les connaissances et les niveaux de confiance qu'ils restituent. Sur ce point, les travaux fondateurs de Jiang et al. 2020, bien qu'antérieurs à l'ère de l'IA générative à proprement parler, établissent un résultat qui demeure structurant : les requêtes (*prompts*) formulées manuellement par les utilisateurs constituent souvent une "borne inférieure" de ce que le modèle sait réellement. Ce résultat, démontré initialement sur des modèles de type BERT et GPT-2, a depuis été confirmé et amplifié par la littérature sur le *prompt engineering* des modèles génératifs : la qualité de l'extraction de connaissance dépend de manière critique de la formulation de la requête. La conception de systèmes de trading fondés sur des LLM requiert donc des mécanismes d'interrogation robustes pour extraire fidèlement l'évaluation du modèle sans induire de biais liés à la formulation du prompt.

3 Calibration et expression de l'incertitude dans les LLM

La capacité d'un système décisionnel fondé sur des LLM à ajuster son comportement dépend de la *calibration* de ces modèles, c'est-à-dire de l'alignement entre la confiance qu'a le modèle en sa réponse et la probabilité réelle que cette réponse soit correcte.

D'une part, Lin, Hilton et Evans 2022 démontrent que des modèles comme GPT-3 peuvent apprendre à exprimer leur incertitude épistémique en langage naturel (probabilité verbalisée, par exemple "confiance à 90 %" ou "confiance moyenne") sans dépendre de l'accès aux *logits* (log-probabilités internes) du modèle. Ces probabilités verbalisées peuvent être remarquablement bien calibrées et se généraliser à de nouvelles tâches après un apprentissage supervisé approprié. Ceci est crucial pour rendre les modèles "honnêtes" quant à leur propre incertitude.

D'autre part, la méthode d'alignement des modèles récents pose un défi majeur pour la surconfiance. Le rapport technique de GPT-4 (**?**) révèle une dynamique paradoxale : si le modèle de base pré-entraîné est hautement calibré (sa confiance prédite correspond généralement à la probabilité d'avoir raison), le processus post-entraînement par apprentissage par renforcement à partir de rétroactions humaines (RLHF) réduit considérablement cette calibration. Après le RLHF, les LLM ont tendance à devenir moins bien calibrés, pouvant afficher une certitude excessive (sur-précision) même lorsqu'ils commettent des erreurs. De plus, les LLM restent sujets aux "hallucinations", produisant des affirmations fausses mais rédigées de manière extrêmement convaincante et confiante.

La littérature indique donc que si les LLM possèdent des capacités prédictives redoutables en finance, leur architecture post-entraînement (RLHF) les prédispose à une détérioration de leur calibration (sur-précision). En psychologie humaine, la surconfiance — et plus spécifiquement le sur-positionnement — est le moteur principal du sur-trading (**?**). Par conséquent, dans un système décisionnel dirigé par des LLM, le risque est double : les agents pourraient non seulement souffrir de sur-précision due à leur entraînement RLHF, mais également manifester une surestimation de la validité de leurs prédictions financières (hallucinations ou probabilités verbalisées biaisées). Évaluer si les traders artificiels sont "surconfiants" demande donc de croiser les métriques de la finance comportementale (surestimation, sur-positionnement, sur-précision) avec les techniques de mesure de l'incertitude épistémique des LLM.

4 Les "erreurs" systématiques des LLM : irrationalité ou rationalité adaptative ?

Avant de conclure que la miscalibration observée chez les LLM constitue une preuve d'irrationalité, il convient d'examiner un argument stimulant avancé par Dorst 2023. Ce dernier montre que GPT-4, un raisonneur probabiliste optimisé, reproduit fidèlement plusieurs biais cognitifs classiquement interprétés comme des preuves d'irrationalité humaine : l'effet de surconfiance dans des tâches à choix forcé (confiance moyenne de 73 % pour un taux de réussite de 53 %), l'erreur de conjonction (*conjunction fallacy*), l'erreur du joueur (*gambler's fallacy*) avec un taux de changement de 60,8 % au lieu des 50 % attendus, ainsi que le conservatisme et l'inertie bayésienne lors de mises à jour de croyances.

La conclusion de Dorst est provocatrice : si un système fondamentalement probabiliste et hautement optimisé comme GPT-4 commet les mêmes "erreurs" que les humains, alors

ces erreurs ne constituent peut-être pas la preuve d'une irrationalité fondamentale. Elles pourraient au contraire être le sous-produit inévitable d'un raisonnement probabiliste opérant sous contraintes computationnelles, conformément à l'hypothèse de "rationalité limitée" (*resource-rationality*) défendue par certains psychologues et philosophes.

Cet argument est directement pertinent pour notre étude. Si la surconfiance des LLM en contexte de trading reflète non pas un défaut d'architecture mais une propriété émergente de tout système de raisonnement probabiliste sous contraintes, alors la miscalibration observée ne devrait pas nécessairement être interprétée comme un biais à corriger, mais pourrait constituer une caractéristique structurelle de la prise de décision en situation d'incertitude radicale — un point sur lequel nous reviendrons dans la discussion.

Il convient toutefois de noter une objection naturelle à cet argument : GPT-4 a été entraîné sur des données produites par des humains, et pourrait simplement reproduire leurs biais par imitation statistique. Dorst rejette cette objection en soulignant que si le modèle ne faisait que répliquer le niveau cognitif moyen de ses données d'entraînement, il ne surpasserait pas les humains sur les examens standardisés, le code ou le raisonnement complexe — ce qui est empiriquement le cas. La coexistence de performances supérieures et de biais identiques suggère que ces "erreurs" émergent du processus d'optimisation lui-même, et non d'une simple contamination par les données.

5 Description de l'expérimentation

5.1 Infrastructure technique et outils

L'environnement expérimental repose sur une architecture logicielle développée par moi même, dont les principaux composants sont décrits ci-dessous.

Langage et *framework*. Le *backend* est écrit en Python 3.11, reposant sur FastAPI et `asyncio` pour la gestion asynchrone des appels API. Le *frontend* de supervision est développé en React (Node.js) et permet le suivi en temps réel des positions, des performances et des décisions de chaque agent.

Données de marché. Les données OHLCV (ouverture, plus haut, plus bas, clôture, volume) sont obtenues via la bibliothèque `yfinance` (Yahoo Finance) sur des intervalles multiples (1 min, 5 min, 15 min, 1 h, 1 j). L'univers couvert comprend environ 450 instruments : actions du S&P 500, du NASDAQ 100, principales cryptomonnaies, et ETFs. Des données alternatives complètent le contexte informationnel : taux de financement perpétuels BTC/ETH via l'API publique Binance Futures, indice *Fear & Greed* via Alternative.me, et calendrier macroéconomique via Finnhub.

Modèles de langage (LLM). Quatre modèles sont mis en concurrence, choisis pour le faible coût de leur API :

- GPT-4o-mini (OpenAI)
- LLaMA-3.3-70B (Meta, via API Groq)
- Gemini 1.5 Flash (Google DeepMind)
- Claude-3 Haiku (Anthropic)

Chaque modèle est instancié de façon indépendante, sans partage de contexte conversationnel entre agents.

Exécution des ordres. L'exécution passe par OKX (cryptomonnaies) via la bibliothèque CCXT et par Interactive Brokers (actions) via l'API IBKR. Un mode *sandbox* (*paper trading*) est disponible pour les deux courtiers. Les résultats présentés dans cette étude sont issus du mode *sandbox*, sauf mention contraire.

Persistance. Les positions ouvertes, l'historique transactionnel et les soldes sont stockés dans une base SQLite locale (via SQLAlchemy). Des rapports de fin de journée (*end-of-day*, EOD) sont générés sous forme de fichiers texte pour chaque agent et réinjectés dans le contexte des appels LLM ultérieurs.

Code source et reproductibilité. Le jeu de données complet (187 transactions avec confiance déclarée et P&L) est disponible en open data sur GitHub [2]. Le code source du système de trading n'est pas rendu public : le volume de développement est considérable, et la diffusion d'un outil de trading autonome opérationnel soulèverait des risques éthiques et de sécurité financière disproportionnés par rapport au bénéfice scientifique marginal de sa publication.

5.2 Protocole expérimental

Note terminologique. Le titre de cette étude emploie le terme "multi-agents" au sens large de *système mettant en concurrence plusieurs modèles décisionnels autonomes*. Toutefois, il convient de préciser que cette architecture ne constitue pas un système multi-agents au sens strict de la littérature en intelligence artificielle distribuée, où les agents interagissent entre eux (négociation, coopération, communication). Dans notre dispositif, les quatre LLM opèrent de manière strictement indépendante et parallèle, sans aucun mécanisme d'interaction ou de communication inter-agents. Il serait donc plus exact de parler de système **multi-modèles** ou de **banc d'essai comparatif**. Ce choix de design est délibéré : l'absence d'interaction permet d'isoler l'effet propre de chaque architecture de modèle sur la calibration, en éliminant les effets de contagion ou de *herding* inter-agents.

Univers d'investissement et mandats. Chaque agent gère de manière autonome un portefeuille virtuel doté d'un capital initial de 100 EUR. Ils opèrent sur un univers d'investissement commun comprenant environ 450 instruments (actions américaines, cryptomonnaies et ETFs). Le système repose sur le principe de "diversification comportementale" : chaque LLM est soumis à un mandat exclusif (*system prompt*) qui l'empêche d'imiter les stratégies de ses pairs, garantissant une diversité d'approches philosophiques face au marché.

Identité de l'information. Chaque cycle de trading (toutes les 10 minutes environ) génère un unique *snapshot* de marché — prix, indicateurs techniques, régime de marché, données alternatives — qui est injecté de façon identique dans le prompt de chaque agent. Les quatre LLM reçoivent donc exactement le même contexte informationnel au même instant. Toute divergence de décision entre agents est ainsi imputable à la différence de modèle (architecture, entraînement, RLHF) et non à une asymétrie d'information. Une nuance doit être mentionnée : si le cycle d'appel API introduit un délai de quelques

2. `https://github.com/Nicolas0208/Les-traders-artificiels-sont-ils-surconfiants-/blob/main/export_calibration_study.csv`

secondes entre le premier et le dernier agent, un mouvement de prix très rapide pourrait théoriquement créer une légère désynchronisation. Ce cas est marginal sur des cycles de 10 minutes.

Pipeline de décision. Le processus décisionnel suit les étapes suivantes à chaque cycle : (1) coupe-circuit macro via le calendrier Finnhub (blocage si événement à fort impact dans les ±30 minutes) ; (2) *screener* de volatilité composite (50 % volatilité *close-to-close*, 30 % volatilité intraday, 20 % volatilité *open-to-close*) sélectionnant les trois meilleurs candidats ; (3) filtre de corrélation (Pearson 30 jours) pour éviter les positions redondantes ; (4) calcul multi-*timeframe* (RSI + EMA sur 15 min / 1 h / 1 j, VWAP 24 h, *Point of Control*) ; (5) classification du régime de marché (ADX, ATR, EMA 21/50) en quatre catégories (TREND_BULL, TREND_BEAR, VOLATILE_RANGE, QUIET_RANGE) ; (6) construction du prompt et envoi à chaque LLM ; (7) *parsing* de la décision (ACHETER / VENDRE / CONSERVER) et exécution ; (8) gestion des positions (*trailing stop*, pyramidation).

Le système fonctionne de manière *event-driven*, générant entre 10 et 24 appels LLM par jour, sur une période d'expérimentation de 72 heures.

Environnement sandbox. Les expériences ont été conduites en *paper trading* (sandbox OKX + IBKR). La sandbox reproduit fidèlement le carnet d'ordres réel mais n'inclut pas l'impact de marché (*market impact*) ni les problèmes de liquidité. Pour des tailles de position petites (≤ 350 EUR par trade), cet écart est négligeable ; il deviendrait significatif à l'échelle institutionnelle.

5.3 Mesure de la surconfiance

Lors de chaque prise de décision, le niveau de confiance de l'agent est capturé de manière implicite. La confiance déclarée correspond à l'inverse du score de risque évalué par le modèle :

$$\text{Confiance} = 100 - \text{score de risque}$$

La définition opérationnelle de la surconfiance repose sur la miscalibration (décalage) entre cette confiance déclarée et la probabilité empirique de succès, mesurée par la capacité de la décision à générer un P&L strictement positif. L'évaluation s'appuie sur la métrique de l'*Expected Calibration Error* (ECE), qui quantifie l'écart absolu moyen entre l'assurance textuelle de l'agent et son taux de victoire réel sur différents intervalles de confiance :

$$ECE = \sum_{m=1}^{M} \frac{|B_m|}{n} \left|\text{acc}(B_m) - \text{conf}(B_m)\right|$$

où M est le nombre d'intervalles (*bins*), B_m l'ensemble des décisions dans l'intervalle m, n le nombre total de décisions, $\text{acc}(B_m)$ le taux de succès empirique et $\text{conf}(B_m)$ la confiance moyenne déclarée dans l'intervalle.

6 Analyse des résultats

L'échantillon de 187 transactions révèle une **ECE globale de 0,2486**, mettant en évidence un phénomène systémique de miscalibration à l'échelle du système multi-modèles.

Le système affiche un taux de succès de 61,5 % pour une confiance moyenne déclarée de 81,9 %, validant l'hypothèse de surconfiance structurelle. Autrement dit, les agents attribuent systématiquement à leurs décisions une probabilité de succès nettement supérieure à leur performance réelle, ce qui correspond à un phénomène classique de sur-précision probabiliste documenté dans la littérature comportementale.

6.1 Hétérogénéité des agents

L'analyse par agent révèle une forte hétérogénéité comportementale, liée à la fois à l'architecture des modèles et à leur exposition aux régimes de marché. Cette hétérogénéité ne se limite pas à la calibration probabiliste : elle se traduit également par des résultats économiques très différenciés en termes de profits cumulés.

Modèle	**Win Rate**	**Confiance Moy.**	**ECE**	**Marge**
Claude-3 Haiku	90,0 %	81,8 %	0,1202	+50 %
Gemini 1.5 Flash	33,3 %	86,2 %	0,5289	+700 %
GPT-4o-mini	43,8 %	77,9 %	0,4419	+20 %
LLaMA-3.3-70B	100 %*	73,7 %	0,2626	+20 %

TABLE 1 – Comparatif des performances et de la calibration par modèle (*échantillon réduit : 23 trades)

Le détail des calibrations par agent est présenté en annexe.
Pour l'interprétation de l'ECE : une valeur inférieure à 0,05 indique une bonne calibration ; une valeur comprise entre 0,05 et 0,15 correspond à une calibration acceptable ; une valeur supérieure à 0,15 révèle une mauvaise calibration caractérisée par une surconfiance ou une sous-confiance significative.

Claude-3 Haiku : Excellente calibration apparente (ECE = 0,1202), mais portée par un régime de marché haussier (*bull run*). La question de la robustesse de cette calibration en marché baissier reste ouverte.

Gemini 1.5 Flash : Pire calibration du système (ECE = 0,5289) dans un contexte de marché baissier, mais profit record (+700 %) grâce à une stratégie "convexe" (gains unitaires très élevés compensant un faible taux de réussite). Ce résultat illustre la tension entre qualité épistémique et performance économique.

GPT-4o-mini : "Surconfiance dans le bruit" — forte assurance dans un environnement volatil sans tendance claire, conduisant à un écart marqué entre confiance et taux de réussite.

LLaMA-3.3-70B : Win rate de 100 % sur un échantillon très réduit (23 trades). L'ECE de 0,2626 reflète paradoxalement une *sous-confiance* : le modèle attribue des niveaux de confiance inférieurs à son taux de réussite empirique. Ce résultat est toutefois insuffisamment robuste statistiquement pour permettre des conclusions fermes.

7 Discussion

7.1 Réplicabilité de l'expérience et robustesse statistique

La transparence quant aux limites méthodologiques de cette étude est essentielle. Plusieurs facteurs favorisent la réplicabilité : le pipeline quantitatif (screener, corrélation, analyse multi-*timeframe*, classification de régime) est entièrement déterministe à données identiques ; les prompts sont versionnés dans le code source ; les données Yahoo Finance et Binance sont publiques et gratuites ; le jeu de données transactionnel est disponible en open data.

En revanche, plusieurs facteurs limitent significativement la réplicabilité. Premièrement, les LLM sont non déterministes (température > 0) et leurs versions évoluent : les fournisseurs mettent à jour les modèles sans toujours versionner explicitement, de sorte qu'une expérience reproduite six mois plus tard avec "GPT-4o-mini" pourrait ne pas utiliser le même modèle sous-jacent. Deuxièmement, le contexte mémoriel de chaque agent (rapport EOD injecté via un mécanisme de type RAG) diffère selon l'historique accumulé : deux *runs* ne partiront pas du même état mémoriel, sauf à réinitialiser les fichiers EOD. Troisièmement, les données de marché passées sont partiellement modifiées *ex post* par Yahoo Finance (ajustements de dividendes, *splits*), ce qui peut affecter les indicateurs calculés sur des séries historiques.

Sur le plan de la robustesse statistique, les métriques actuellement collectées (win rate, ECE, P&L cumulé) sont des statistiques descriptives sur une fenêtre de 72 heures. Elles ne permettent pas, à elles seules, d'établir une performance statistiquement significative, pour trois raisons principales. D'abord, le nombre de trades par agent est faible (de 23 à 72), ce qui ne permet pas à la loi des grands nombres de distinguer compétence et chance. Ensuite, les séries de P&L en trading sont non normales (*fat tails*, autocorrélation, changements de régime), ce qui invalide les tests t standard. Enfin, la comparaison simultanée de quatre agents sur de nombreux paramètres expose au biais de tests multiples (*multiple testing*).

Pour renforcer la robustesse, plusieurs tests statistiques pourraient être mobilisés dans des travaux ultérieurs : tests de permutation sur les P&L (comparaison à une distribution nulle obtenue par *shuffling* des décisions), *bootstrap* sur le win rate et l'ECE pour obtenir des intervalles de confiance à 95 %, analyse *walk-forward* pour détecter le surajustement temporel, et test de Diebold-Mariano pour comparer la précision directionnelle de deux agents. En l'état, les résultats doivent être présentés comme **préliminaires et exploratoires**, non comme une preuve d'alpha statistiquement certifiée.

7.2 Corriger les biais : une question normative

L'identification d'une surconfiance structurelle chez les agents LLM soulève naturellement la question de sa correction. Plusieurs stratégies sont envisageables. Sur le plan structurel, l'injection explicite de toutes les données factuelles dans le prompt (prix, indicateurs, régime) élimine les hallucinations factuelles et réduit le biais de disponibilité. L'imposition d'un format de réponse strict (JSON ou *micro-update*) limite les rationalisations post-hoc verbeuses. La réinjection des erreurs passées via le rapport EOD réduit la répétition des mêmes mauvaises décisions. Enfin, des mécanismes de recalibration probabiliste *a posteriori* (par exemple, ajuster la confiance déclarée par une fonction de correction apprise sur l'historique) pourraient être intégrés.

Toutefois, la question de savoir s'il *faut* corriger ces biais mérite une discussion plus

nuancée, comme le suggère l'argument de Dorst 2023 présenté en section 4. Trois arguments militent pour une correction partielle seulement.

Premièrement, certains biais sont adaptatifs. Le biais de récence, par exemple, constitue une heuristique efficace sur des marchés à momentum (ce qui a monté récemment continue souvent de monter à court terme). Le corriger intégralement reviendrait à ignorer le momentum, qui est une prime de risque documentée empiriquement.

Deuxièmement, dans un cadre d'incertitude radicale au sens de Keynes, un agent parfaitement rationnel — au sens bayésien strict — serait paralysé face à l'impossibilité de former des distributions de probabilité complètes (problème d'Ellsberg). Un biais de confiance modéré peut permettre d'agir là où l'inaction est coûteuse, ce qui rejoint l'argument de la rationalité limitée (*resource-rationality*).

Troisièmement, contrairement aux biais humains qui varient avec l'humeur, la fatigue et la pression sociale, les biais d'un LLM donné (à version constante) sont reproductibles et potentiellement prévisibles. On pourrait donc les *cartographier et les arbitrer* plutôt que de les éliminer — en exploitant leur stabilité comme un paramètre de modèle plutôt qu'en les traitant comme un défaut à supprimer.

7.3 La place du trader humain face à un système potentiellement moins biaisé

Si un système multi-modèles LLM démontre empiriquement une meilleure discipline décisionnelle que le trader humain moyen — moins de *panic selling*, absence de fatigue, cohérence du *sizing* — la question de la valeur ajoutée résiduelle du trader se pose avec acuité.

Ce que la machine ne peut pas (encore) faire. Les LLM sont entraînés sur le passé. Un événement structurellement nouveau (conflit géopolitique inédit, choc réglementaire, découverte technologique rupturiste) est sous-pondéré dans le *prior* du modèle. Le trader expert, s'il suit l'actualité en temps réel, peut détecter plus tôt la rupture de régime. Par ailleurs, dans le cadre réglementaire actuel (MiCA en Europe, SEC aux États-Unis), la responsabilité de la décision d'investissement reste humaine : un système autonome n'est pas une personne morale responsable. Enfin, la définition des objectifs (niveau de risque, horizon, tolérance au *drawdown*) relève d'un acte humain porteur de valeurs, pas seulement de calcul.

Le trader comme architecte. Dans un tel système, le trader humain migre d'un rôle de décideur vers un rôle d'*architecte* : architecte de la politique de risque (paramétrage des coupe-circuits, seuils de *sizing*), concepteur du prompt (interface entre la vision humaine du marché et la cognition du LLM), arbitre de second rang lorsque les modèles divergent fortement, et évaluateur de la robustesse (*backtesting*, analyse des biais, *walk-forward*).

La question de l'alpha résiduel. Si les LLM incorporent l'information publique plus complètement et plus rapidement que tout trader individuel, alors l'alpha humain ne peut plus provenir de l'information publique. Il ne pourrait venir que de l'information privée (encadrée réglementairement), de la construction de systèmes LLM supérieurs à ceux des concurrents (un *méta-alpha* systémique), ou de la gestion des relations institutionnelles et de la liquidité à grande échelle.

Biais humain *versus* biais machine : un faux dilemme ? Il serait réducteur d'opposer un humain biaisé à une machine rationnelle. Les LLM héritent des biais présents dans leurs données d'entraînement, qui sont précisément produites par des humains biaisés. La différence est de nature, pas de degré : le biais humain est dynamique, contextuel, émotionnel et variable dans le temps ; le biais LLM est statique (à version constante), systématique, cartographiable, et donc potentiellement arbitrable. Un système hybride humain-LLM bien conçu pourrait combiner la flexibilité adaptative de l'humain (détection de ruptures, redéfinition des objectifs) avec la discipline mécanique du LLM (pas de panique, pas de fatigue, respect du *sizing*).

8 Conclusion

Cette expérimentation apporte une contribution empirique à l'intersection de la finance comportementale et de l'économie de l'intelligence artificielle en évaluant, dans un cadre contrôlé, la calibration probabiliste de traders artificiels fondés sur des modèles de langage. En mobilisant le concept d'*Expected Calibration Error* comme métrique opérationnelle de la sur-précision, l'analyse met en évidence une mauvaise calibration systémique au sein du système multi-modèles : les agents attribuent en moyenne à leurs décisions un niveau de confiance significativement supérieur à leur taux de succès empirique (81,9 % de confiance déclarée pour 61,5 % de réussite, ECE = 0,2486). Ce résultat suggère que les agents LLM reproduisent une forme de surconfiance probabiliste analogue à celle observée chez les traders humains, telle que conceptualisée par Moore et Healy 2008.

Les résultats confirment l'hypothèse d'une sur-précision structurelle dans les systèmes décisionnels reposant sur des LLM, cohérente avec les travaux soulignant la dégradation de la calibration après les phases d'alignement par RLHF (**?**). Toutefois, l'éclairage de Dorst 2023 invite à nuancer cette interprétation : si un raisonneur probabiliste optimisé comme GPT-4 reproduit les mêmes "erreurs" que les humains, la miscalibration pourrait refléter non pas un défaut, mais une propriété émergente de tout système de raisonnement probabiliste sous contraintes computationnelles.

L'analyse par agent révèle une hétérogénéité marquée des comportements et des performances, indiquant que la surconfiance n'est pas uniforme mais dépend à la fois des architectures de modèles et du contexte de marché. Le cas de Gemini — forte miscalibration mais profit record — illustre que la qualité épistémique des probabilités et la performance économique ne sont pas nécessairement corrélées à court terme, une tension encore peu explorée dans la littérature.

Ces résultats, qu'il convient de qualifier de préliminaires en l'absence de tests statistiques de robustesse, ouvrent plusieurs pistes de recherche. Sur le plan méthodologique, l'extension de la période d'observation (minimum six mois) et la mise en place de tests de permutation et de *bootstrap* sont nécessaires pour distinguer compétence et chance. Sur le plan théorique, la question normative de la correction des biais — entre élimination et exploitation de leur stabilité — constitue un enjeu central pour la conception de systèmes décisionnels hybrides humain-IA. Sur le plan pratique, la migration du rôle du trader humain, de décideur à architecte de systèmes, représente une transformation profonde dont les implications économiques et réglementaires restent largement à explorer.

En définitive, cette étude montre que les LLM ne sont pas seulement des processeurs d'information performants : lorsqu'ils sont intégrés dans des architectures décisionnelles autonomes, ils reproduisent des dynamiques cognitives proches de celles observées chez les investisseurs humains. L'analyse de ces biais émergents constitue un enjeu central pour

la compréhension et la régulation des futurs systèmes financiers pilotés par intelligence artificielle.

Références

Dorst, Kevin (2023). *ChatGPT undermines the case for human irrationality*. Substack, 19 août 2023. Dorst est philosophe à MIT, spécialiste de l'épistémologie et de la rationalité. URL : `https://kevindorst.substack.com/p/chatgpt-undermines-the-case-for-human`.

Glaser, Markus et Martin Weber (2007). "Overconfidence and trading volume". In : *Geneva Risk and Insurance Review* 32, p. 1-36.

Jiang, Zhengbao et al. (2020). "How Can We Know What Language Models Know ?" In : *Transactions of the Association for Computational Linguistics* 8, p. 423-438.

Lin, Stephanie, Jacob Hilton et Owain Evans (2022). "Teaching models to express their uncertainty in words". In : *arXiv preprint arXiv :2205.14334*.

Lopez-Lira, Alejandro et Yuehua Tang (2025). "Can ChatGPT Forecast Stock Price Movements ? Return Predictability and Large Language Models". In : *Working Paper, University of Florida*.

Moore, Don A et Paul J Healy (2008). "The trouble with overconfidence". In : *Psychological Review*. Draft version (2007) available via SSRN.

OpenAI (2023). *GPT-4 Technical Report*. Rapp. tech. arXiv preprint arXiv :2303.08774. OpenAI.

La figure 1 illustre l'évolution du portefeuille agrégé sur la période d'expérimentation. Malgré une calibration probabiliste imparfaite, les agents parviennent à générer des performances économiques positives dans certains contextes de marché. Ce résultat souligne un point central : la qualité de la calibration et la performance financière ne sont pas nécessairement corrélées à court terme.

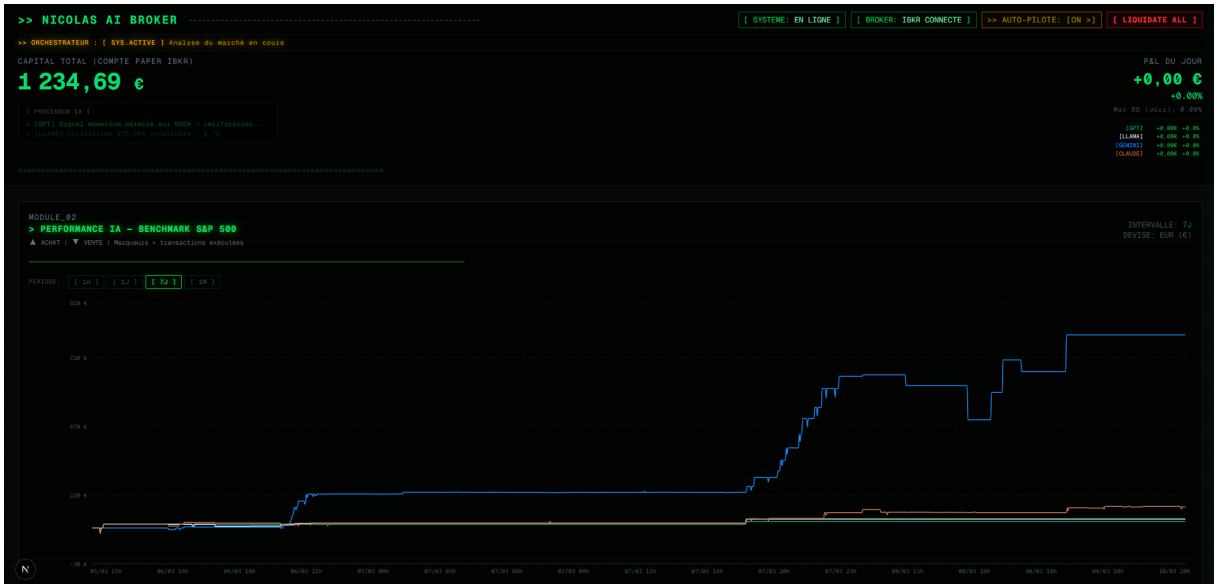


FIGURE 1 – Résultats financiers au jour 3 (208,67 % de marge). Capture d'écran de l'application de supervision développée par mes soins (interface React/Node.js).

9 Annexe

Détail de la calibration des agents en fonction des intervalles de confiance déclarés. Pour chaque intervalle, je reporte le nombre d'observations, la confiance moyenne déclarée, le taux de succès empirique ainsi que l'écart entre probabilité déclarée et fréquence observée.

Agent GPT-4o-mini (32 trades)

Bin	N	Confiance moyenne	Win Rate	Écart
40–60	4	60,0 %	100,0 %	−0,400 (Sous-confiance)
60–80	26	80,0 %	34,6 %	+0,454 (Surconfiance)
80–100	2	87,0 %	50,0 %	+0,370 (Surconfiance)

Agent Gemini 1.5 Flash (72 trades)

Bin	N	Confiance moyenne	Win Rate	Écart
60–80	34	80,0 %	29,4 %	+0,506 (Surconfiance)
80–100	38	91,8 %	36,8 %	+0,549 (Surconfiance)

Agent LLaMA-3.3-70B (23 trades)

Bin	N	Confiance moyenne	Win Rate	Écart
20–40	4	30,0 %	100,0 %	−0,700 (Sous-confiance)
60–80	10	80,0 %	100,0 %	−0,200 (Sous-confiance)
80–100	9	86,2 %	100,0 %	−0,138 (Sous-confiance)

Agent Claude-3 Haiku (60 trades)

Agrégation de tous les agents (187 trades)

Table 2 – Calibration agrégée – Tous les agents

Bin	N	Confiance moyenne	Win Rate	Écart
20–40	4	30,0 %	100,0 %	−0,700 (Sous-confiance)
40–60	6	60,0 %	83,3 %	−0,233 (Sous-confiance)
60–80	108	79,6 %	60,2 %	+0,194 (Surconfiance)
80–100	69	90,4 %	59,4 %	+0,309 (Surconfiance)

Bin	N	Confiance moyenne	Win Rate	Écart
40–60	2	60,0 %	50,0 %	+0,100 (Surconfiance)
60–80	38	78,8 %	94,7 %	−0,159 (Sous-confiance)
80–100	20	89,8 %	85,0 %	+0,048 (Calibration correcte)

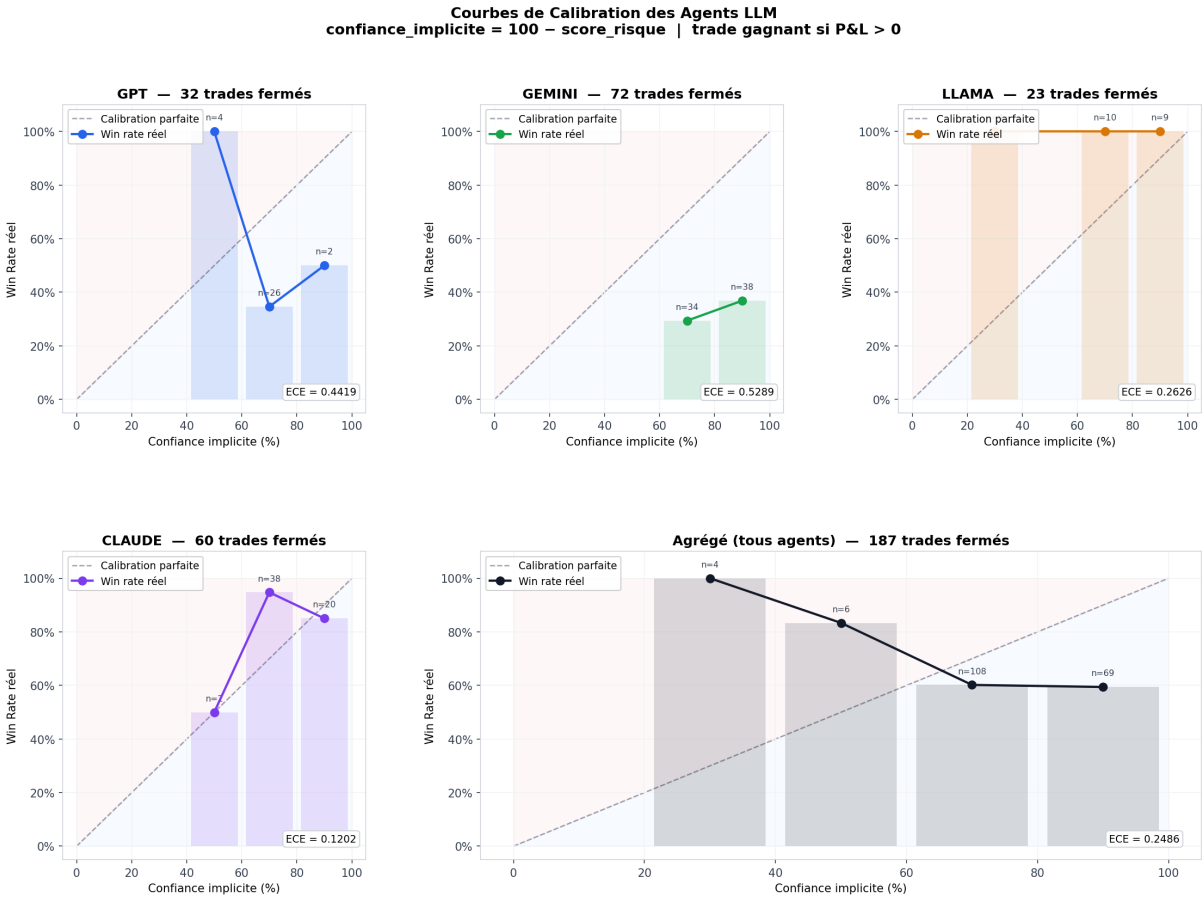


FIGURE 2 – Courbes de calibration des agents LLM. La diagonale pointillée représente la calibration parfaite ; un point au-dessus indique une sous-confiance, un point en dessous une surconfiance.

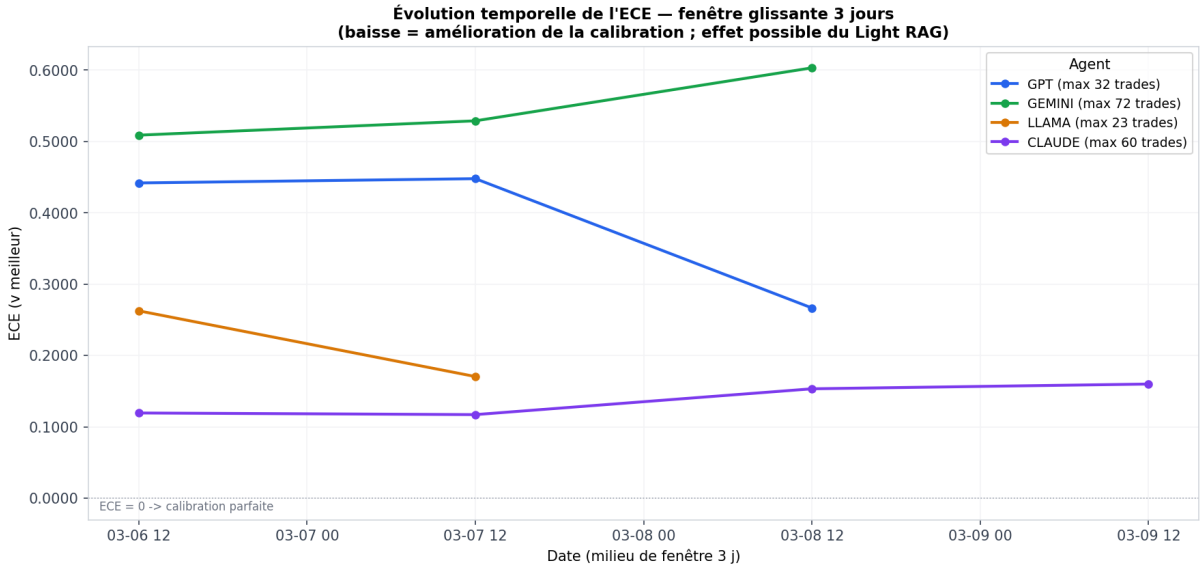


FIGURE 3 – Évolution temporelle de l'*Expected Calibration Error* (fenêtre glissante de 3 jours). Une baisse indique une amélioration de la calibration au fil du temps.

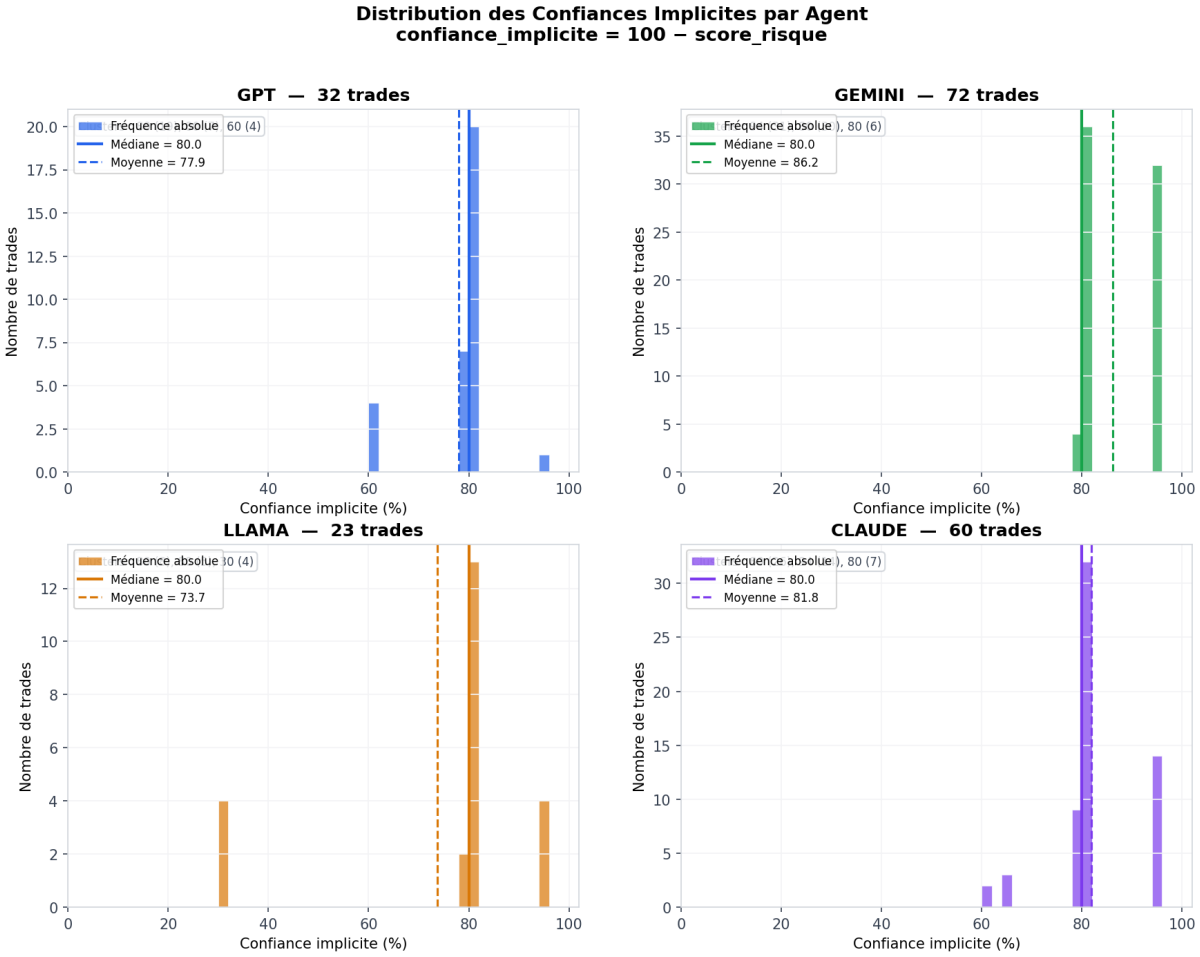


FIGURE 4 – Distribution des confiances implicites par agent. La concentration des valeurs autour de 80 % pour la plupart des agents suggère un “ancrage” des LLM sur des niveaux de confiance élevés.